Dengue nas capitais do Nordeste

Previsão semanal de casos e risco de ultrapassar o limiar epidemiológico

Relatório técnico | Séries Temporais e Análise Preditiva | Atualização dos dados: 09/11/2026

Resumo

O projeto prevê casos semanais de dengue nas nove capitais do Nordeste para quatro semanas à frente e estima a probabilidade de a incidência superar o limiar oficial do Moving Epidemics Method (MEM). O painel usa dados públicos do InfoDengue, clima NASA POWER e população DATASUS/SVS. O recorte de capitais mantém uma unidade comparável e cobertura climática uniforme; não representa todos os municípios nordestinos.

No backtest walk-forward com 24 origens, a Binomial Negativa global teve o menor RMSE (54,68 casos por capital-semana), melhor que os outros quatro modelos e que o baseline sazonal. O classificador de cruzamento MEM obteve F1=0,712. Diebold-Mariano não encontrou diferença significativa entre Binomial Negativa e SARIMAX em nenhum horizonte. A previsão condicionada à última publicação disponível (25/10/2026) soma cerca de 167 a 176 casos por semana nas nove capitais entre 01 e 22/11; nenhuma capital excede probabilidade MEM 0,5.

Perguntas do projeto

Prever casos prováveis de cada capital nas próximas quatro semanas e estimar em qual semana a incidência pode cruzar o limiar MEM.

1. Dados e painel

O painel exploratório contém 9 capitais por 584 semanas, de 04/01/2015 a 08/03/2026 (5.256 linhas, sem chaves duplicadas). A modelagem foi atualizada separadamente até a SE 43/2026, iniciada em 25/10/2026, com 5.553 semanas-capital. A diferença de período e versão fica explícita: os gráficos da EDA não incorporam a extração posterior do backtest.

A variável-alvo é `casprov`, casos prováveis por semana. A incidência por 100 mil habitantes complementa a contagem; `nivel_inc_mem == 2` indica ultrapassagem do limiar oficial MEM. A população anual DATASUS/SVS é carregada para frente a partir do último valor conhecido até aquela data, sem usar anos futuros.

Fontes e unidades

InfoDengue/Mosqlimate: casos prováveis e indicador MEM. EDA climática: reanálise ERA5/Copernicus organizada pelo Mosqlimate. Modelagem climática: NASA POWER Daily Point, temperatura a 2 m (°C), precipitação corrigida acumulada (mm/semana) e umidade relativa (%). População: DATASUS/SVS. NASA POWER é estimativa em grade, não medição em estação local.

Casos por capital na base exploratória

Capital	Média semanal	Mediana	Máximo
São Luís	36,0	21	585
Teresina	95,4	37	1.742
Fortaleza	232,9	84	2.771
Natal	172,6	77	1.749
João Pessoa	120,4	76	628
Recife	163,5	68,5	1.998
Maceió	84,7	31	991
Aracaju	26,4	10	239
Salvador	111,6	58	951

Na série agregada, a mediana entre semanas positivas é 47 casos; P90=275 e P99=1.144. A distribuição é assimétrica e varia bastante entre capitais, então comparamos contagem e incidência e usamos modelos de contagem com sobredispersão.

2. Análise exploratória

As séries por capital e os perfis por semana epidemiológica exibem ciclos anuais, mas a intensidade muda entre cidades e anos. A STL foi aplicada a log(1+casos) com período de 52 semanas. Tendência resume mudanças graduais; sazonalidade resume o padrão anual; resíduo contém flutuações que os dois componentes não explicam. Um pico residual pode corresponder a um surto real.

ADF e KPSS

Na escala log(1+casos), os testes concordaram com estacionariedade em 8 de 9 capitais e não concordaram com não estacionariedade em nenhuma; os demais resultados foram discordantes ou inconclusivos. ADF tem hipótese nula de raiz unitária; KPSS tem hipótese nula de estacionariedade. Por isso, diferenças são avaliadas dentro do treino de cada janela, sem impor diferenciação fixa.

ACF/PACF indicam persistência de curto prazo e estrutura anual. Lags de casos entre 1 e 8 semanas e lag 52 foram considerados candidatos; a validação walk-forward decide quais ajudam.

Faltantes e extremos

Não havia valores ausentes no alvo nem nas células climáticas da EDA. Zero observado não é confundido com dado faltante. A regra IQR sinalizou 575 valores altos; 538 coincidem com semanas marcadas pelo indicador MEM. Nenhum pico foi removido ou winsorizado: só corrigiríamos um registro com prova de erro de fonte ou unidade.

A série `casprov` da extração InfoDengue e a série histórica diferem em 183 de 5.256 observações (3,48%); a maior diferença absoluta é 159 casos. Mantivemos a extração associada ao alerta MEM e registramos a auditoria. A fonte pode revisar valores depois de publicados.

3. Correlação e seleção de variáveis

Pearson e Spearman foram calculados por capital. A CCF examinou clima observado 2 a 8 semanas antes dos casos, após retirar a climatologia semanal de cada capital. Granger testou ganho de informação preditiva e os p-valores foram corrigidos por Benjamini-Hochberg (BH). Esses testes descrevem associação e não demonstram causalidade.

Variável	Evidência exploratória	Decisão final
Temperatura	Associação fraca; Granger sem significância após BH.	Mantida como único clima após ablation temporal.
Precipitação	CCF ajustada próxima de zero.	Excluída: não reduziu o RMSE.
Umidade relativa	CCF ajustada próxima de zero; lags redundantes.	Excluída: não reduziu o RMSE.

Nenhuma combinação capital, variável e lag permaneceu significativa em Granger após BH. Entre 40 preditores candidatos, 22 têm VIF acima de 5 e 22 acima de 10, o que indica redundância entre lags.

Ablation no mesmo walk-forward

Na Binomial Negativa, RMSE foi 54,68 com temperatura, 56,03 sem clima e 55,55 com temperatura, chuva e umidade. O ganho contra ausência de clima é modesto (2,4%). Mantemos temperatura por desempenho comparativo e parcimônia; isso não prova que chuva e umidade não tenham relação biológica com dengue.

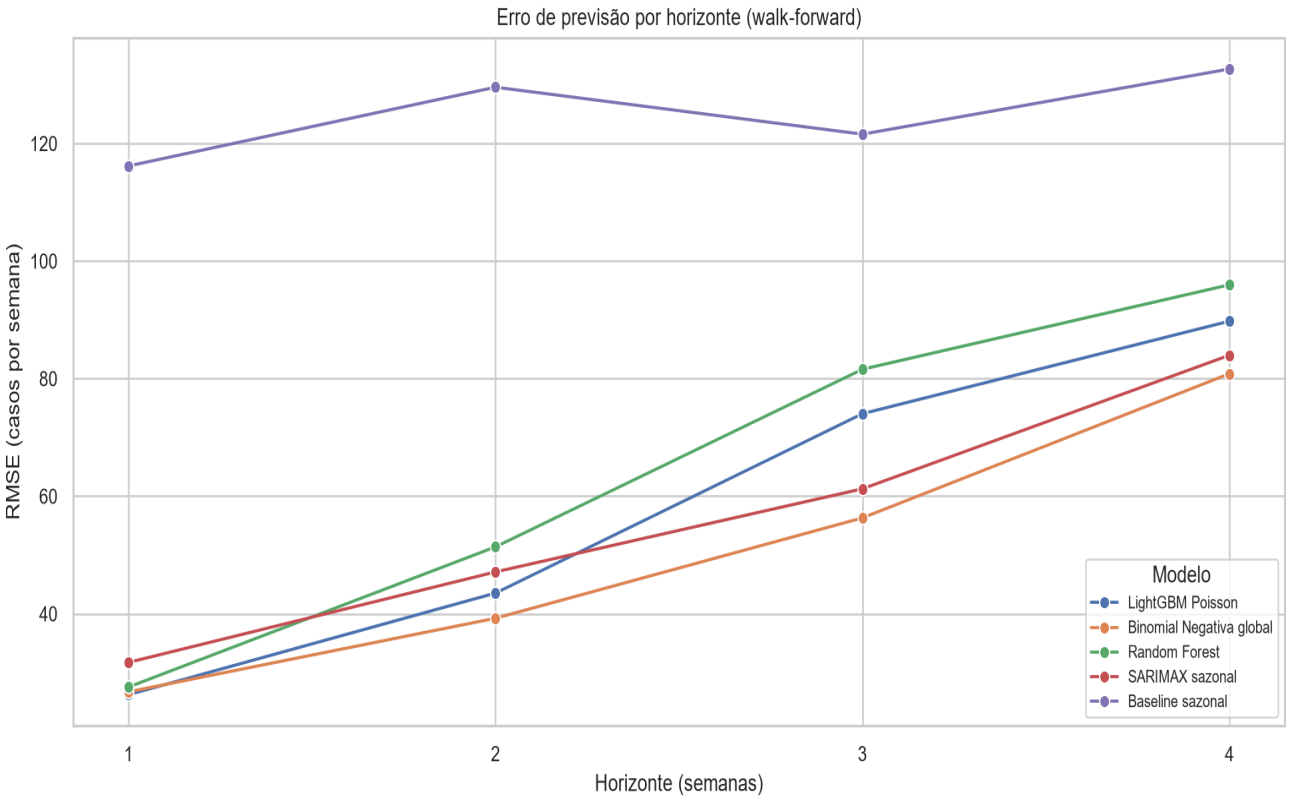
Para cada horizonte h, clima só entra com defasagem pelo menos h, ou com previsão climática disponível na origem. Casos recentes, lag sazonal de 52 semanas e calendário formam a base dos modelos.

4. Modelos e validação temporal

Foram comparados cinco modelos de três famílias: baseline sazonal; modelos estatísticos (Binomial Negativa global e SARIMAX sazonal por capital); e aprendizado de máquina (Random Forest global e LightGBM com perda Poisson). O horizonte de quatro semanas corresponde à pergunta do projeto.

A validação usa 24 origens expansivas entre 21/01/2024 e 27/09/2026. Em cada origem, o treino termina na origem; não houve embaralhamento. Cada modelo faz previsão direta nos horizontes 1 a 4. São 864 previsões por modelo (9 capitais x 24 origens x 4 horizontes).

Modelo	MAE	RMSE	MAPE %	sMAPE %	MASE
Binomial Negativa global	26,91	54,68	42,07	32,18	0,250
SARIMAX sazonal	26,50	59,23	34,20	30,17	0,256
LightGBM Poisson	29,09	63,49	42,15	31,45	0,276
Random Forest	30,11	69,40	41,14	31,33	0,279
Baseline sazonal (52 sem.)	70,18	125,18	112,08	66,87	0,639



MAPE é calculado só em semanas positivas; sua cobertura é 99,65%. MASE abaixo de 1 significa erro menor que o baseline sazonal. Intervalos nominais de 90% também foram avaliados: cobertura empírica agregada foi 98,61% para Binomial Negativa, 94,56% para SARIMAX, 87,63% para LightGBM, 92,25% para Random Forest e 94,68% para o baseline. Cobertura acima do nominal não garante intervalos estreitos.

5. Eventos MEM e previsão de quatro semanas

Com ponto de corte de probabilidade 0,5, o classificador LightGBM de cruzamento MEM teve precisão 0,635, recall 0,810 e F1 0,712 no agregado (864 previsões; prevalência 16,4%). O F1 cai com o horizonte: 0,850 na semana 1, 0,800 na 2, 0,623 na 3 e 0,581 na 4. O corte afeta o equilíbrio entre precisão e recall.

Previsão mais recente salva, origem 25/10/2026

Semana iniciada	Casos somados	Incidência / 100 mil	Prob. MEM média
01/11/2026	167	1,39	2,87%
08/11/2026	169	1,41	0,70%
15/11/2026	172	1,43	0,92%
22/11/2026	176	1,47	1,30%

Nenhuma capital teve probabilidade prevista igual ou maior que 0,5 de cruzar MEM em qualquer das quatro semanas. A maior incidência pontual é cerca de 5,10 por 100 mil em João Pessoa na semana de 22/11, mas a probabilidade estimada permanece abaixo do corte. Os intervalos municipais estão nos arquivos de previsão.

A origem é o último dado disponível (SE43, início em 25/10). Na data da atualização (09/11), parte do horizonte já tinha começado ou terminado. São previsões condicionadas à última publicação, não alertas em tempo real.

O teste Diebold-Mariano comparou os dois melhores modelos por perda quadrática regional, horizonte e variância HAC. Todos os p-valores ficaram acima de 0,05 (0,123 a 0,490); isso não prova equivalência.

Limitações: nove capitais, revisões da base epidemiológica, estimativas meteorológicas em grade, clima ERA5 na EDA versus NASA POWER no modelo, e apenas 24 origens recentes para o teste DM.

6. Limitações e reprodutibilidade

Os resultados se referem às nove capitais e não devem ser generalizados para todos os municípios do Nordeste. Há atraso e revisões na publicação dos casos; por isso, as previsões são condicionadas ao último dado disponível e não equivalem a alertas em tempo real.

A análise exploratória usa um painel encerrado em 08/03/2026 com clima ERA5; a etapa de modelagem usa uma extração posterior, encerrada em 25/10/2026, com clima NASA POWER. As fontes, períodos e unidades são diferentes e estão descritos no dicionário. Comparações climáticas finais foram calculadas com a fonte usada na modelagem.

NASA POWER fornece estimativas meteorológicas em grade, não medições de estações locais. O ganho associado à temperatura foi pequeno, e análises de associação não demonstram causa e efeito. O teste Diebold-Mariano também teve amostra limitada a 24 origens.

Reprodução

Os notebooks estão em `notebooks/`; os scripts em `src/`; as bases tratadas em `data/processed/`; e as tabelas e figuras em `reports/`. O README informa a ordem de execução, dependências e fontes públicas.

Fontes: InfoDengue API (https://info.dengue.mat.br/services/api); Mosqlimate (https://sprint.mosqlimate.org/data/); NASA POWER (https://power.larc.nasa.gov/docs/services/api/temporal/daily/); DATASUS/SVS, conforme o dicionário de variáveis.

Roteiro de defesa: perguntas prováveis

Por que usar capitais, e não todos os municípios?

O enunciado permite capitais ou municípios da Paraíba. As capitais formam painel comparável com cobertura climática uniforme; não generalizamos aos demais municípios.

Por que Binomial Negativa?

Casos são contagens com sobredispersão. A Binomial Negativa teve o menor RMSE fora da amostra; SARIMAX teve MAE um pouco menor.

Como evitou vazamento temporal?

24 origens cronológicas; em cada uma o treino termina na origem. Os quatro alvos seguintes ficam fora do treino e as defasagens de clima respeitam disponibilidade.

Por que não removeu os picos?

A triagem IQR sinalizou observações, mas 538 coincidem com evento MEM. Surtos são o fenômeno previsto; não houve evidência de erro de origem ou unidade.

Por que manter só temperatura?

A ablation pareada teve RMSE 54,68 com temperatura, 56,03 sem clima e 55,55 com três climas. O ganho é pequeno; escolhemos a especificação parcimoniosa.

O modelo sinaliza surto nas próximas semanas?

Nenhuma capital tem probabilidade MEM igual ou maior que 0,5. A origem é 25/10/2026; como os dados têm atraso de publicação, o horizonte estava parcialmente no passado em 09/11.

Qual é a limitação principal?

O painel cobre nove capitais, os casos têm atraso e revisão, o clima é estimado em grade e o backtest dispõe de 24 origens. Por isso, os resultados não devem ser tratados como alertas em tempo real nem generalizados a todos os municípios.